Parcial 1

Teoría de Aprendizaje de Máquina

Luis Fernando Gamba Bedoya
C.C. 1058138131

Santiago Galeano Castaño
C.C. 1002652457

2026-2
Profesor: Diego Armando Pérez Rosero
Tema: Métodos kernel, espacios de características y formulación matricial

1 Formulación matricial

Sean $\{(x_n, t_n)\}_{n=1}^N$ observaciones i.i.d., con $x_n \in \mathbb{R}^P$ y $t_n \in \mathbb{R}$. Se define un mapeo de características

$$\phi : \mathbb{R}^P \longrightarrow \mathbb{R}^Q.$$

Para un vector de pesos $w \in \mathbb{R}^Q$, consideramos el modelo lineal en el espacio de características

$$t_n = \phi(x_n)^\top w + \eta_n, \qquad \eta_n \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma_\eta^2).$$

Al apilar las N observaciones se obtienen la matriz de diseño, el vector de respuestas y el vector de ruido:

$$\Phi = \begin{bmatrix} \phi(x_1)^\top \\ \vdots \\ \phi(x_N)^\top \end{bmatrix} \in \mathbb{R}^{N \times Q},$$
$$t = \begin{bmatrix} t_1 & \cdots & t_N \end{bmatrix}^\top \in \mathbb{R}^{N \times 1},$$
$$\eta = \begin{bmatrix} \eta_1 & \cdots & \eta_N \end{bmatrix}^\top \in \mathbb{R}^{N \times 1}.$$

Así, el modelo conjunto queda expresado como

$$\underbrace{t}_{N\times 1} = \underbrace{\Phi}_{N\times Q}\,\underbrace{w}_{Q\times 1} + \underbrace{\eta}_{N\times 1}.$$

1.1 Mínimos cuadrados ordinarios (OLS)

Función objetivo

El estimador de mínimos cuadrados ordinarios minimiza la norma euclidiana del vector de residuos $r(w) = t - \Phi w \in \mathbb{R}^{N\times 1}$:

$$\widehat{w}_{\text{OLS}} \in \arg\min_{w\in\mathbb{R}^Q} J(w), \tag{1}$$

$$J(w) = \frac{1}{2}\|t - \Phi w\|_2^2 = \frac{1}{2}(t - \Phi w)^\top (t - \Phi w). \tag{2}$$

El factor $1/2$ se incluye por conveniencia al derivar. Expandimos el producto residual:

$$\begin{aligned} J(w) &= \frac{1}{2}(t - \Phi w)^\top (t - \Phi w) \\ &= \frac{1}{2}\left[t^\top t - t^\top \Phi w - (\Phi w)^\top t + (\Phi w)^\top \Phi w\right]. \end{aligned}$$

Los dos términos cruzados son escalares. En particular,

$$(\Phi w)^\top t = w^\top \Phi^\top t = (t^\top \Phi w)^\top = t^\top \Phi w,$$

pues la transpuesta de un escalar no lo cambia. Para el último término,

$$(\Phi w)^\top \Phi w = w^\top \Phi^\top \Phi w.$$

Por tanto, la función objetivo expandida queda

$$J(w) = \frac{1}{2}t^\top t - t^\top \Phi w + \frac{1}{2}w^\top \Phi^\top \Phi w.$$

Las dimensiones confirman que cada término de $J(w)$ es un escalar:

$$\begin{aligned} t^\top t &\in \mathbb{R}^{(1\times N)(N\times 1)} = \mathbb{R}^{1\times 1}, \\ t^\top \Phi w &\in \mathbb{R}^{(1\times N)(N\times Q)(Q\times 1)} = \mathbb{R}^{1\times 1}, \\ w^\top \Phi^\top \Phi w &\in \mathbb{R}^{(1\times Q)(Q\times N)(N\times Q)(Q\times 1)} = \mathbb{R}^{1\times 1}. \end{aligned}$$

Derivada y ecuaciones normales

Derivando con respecto al vector columna w,

$$\begin{aligned} \frac{d}{dw}(t^\top t) &= 0_{Q\times 1}, \\ \frac{d}{dw}(t^\top \Phi w) &= \Phi^\top t, \\ \frac{d}{dw}\left(\frac{1}{2}w^\top \Phi^\top \Phi w\right) &= \Phi^\top \Phi w, \end{aligned}$$

ya que $\Phi^\top \Phi$ es simétrica. Por consiguiente,

$$\frac{dJ(w)}{dw} = \Phi^\top \Phi w - \Phi^\top t.$$

Igualando la derivada a cero se obtienen las ecuaciones normales:

$$\Phi^\top \Phi w = \Phi^\top t.$$

Existencia y unicidad

1. Verificación del mínimo. La función de error de mínimos cuadrados es

$$J(w) = \frac{1}{2}\|t - \Phi w\|_2^2.$$

Su Hessiana es

$$H = \Phi^\top \Phi.$$

Para cualquier vector $v \in \mathbb{R}^Q$,

$$v^\top H v = v^\top \Phi^\top \Phi v = \|\Phi v\|_2^2 \geq 0.$$

Como una norma al cuadrado nunca es negativa, H es semidefinida positiva. Por tanto, $J(w)$ es convexa y todo punto crítico es un mínimo global. Las ecuaciones normales se obtienen igualando el gradiente a cero:

$$\Phi^\top \Phi w = \Phi^\top t.$$

2. Existencia de la solución. La existencia significa que hay al menos un vector de pesos que minimiza el error. En mínimos cuadrados siempre existe al menos un minimizador, incluso si $\Phi^\top \Phi$ no es invertible. Para verlo, observamos que

$$\Phi^\top \Phi v = 0 \quad \Longleftrightarrow \quad v^\top \Phi^\top \Phi v = \|\Phi v\|_2^2 = 0 \quad \Longleftrightarrow \quad \Phi v = 0.$$

Así,

$$\ker(\Phi^\top \Phi) = \ker(\Phi), \qquad \operatorname{rank}(\Phi^\top \Phi) = \operatorname{rank}(\Phi).$$

Además,

$$\operatorname{col}(\Phi^\top \Phi) \subseteq \operatorname{col}(\Phi^\top),$$

y ambos espacios tienen la misma dimensión, por lo que

$$\operatorname{col}(\Phi^\top \Phi) = \operatorname{col}(\Phi^\top).$$

En consecuencia, $\Phi^\top t$ pertenece al espacio columna de $\Phi^\top \Phi$ y las ecuaciones normales tienen al menos una solución w_*. Como

$$\nabla J(w_*) = \Phi^\top \Phi w_* - \Phi^\top t = 0,$$

y J es convexa, w_* es un mínimo global. Por tanto,

$$\exists\, w_* \in \mathbb{R}^Q \quad \text{tal que} \quad J(w_*) = \min_{w \in \mathbb{R}^Q} J(w).$$

3. Unicidad de la solución. La unicidad significa que existe un solo vector de pesos que minimiza el error. Al cambiar los pesos de w a $w+v$, las predicciones permanecen iguales exactamente cuando

$$\Phi(w+v) = \Phi w \quad \Longleftrightarrow \quad \Phi v = 0 \quad \Longleftrightarrow \quad v \in \ker(\Phi).$$

Por ello, la solución es única si y solo si

$$\ker(\Phi) = \{0\},$$

lo cual equivale a que las Q columnas de Φ sean linealmente independientes:

$$\operatorname{rank}(\Phi) = Q.$$

En ese caso, para todo $v \neq 0$,

$$v^\top \Phi^\top \Phi v = \|\Phi v\|_2^2 > 0,$$

por lo que $\Phi^\top \Phi$ es definida positiva e invertible. Como Φ tiene N filas y Q columnas,

$$\operatorname{rank}(\Phi) \leq \min(N, Q).$$

Así, es necesario que $N \geq Q$, aunque esta condición por sí sola no garantiza que las columnas sean independientes.

Si $\Phi^\top \Phi$ es invertible, multiplicamos las ecuaciones normales por su inversa y obtenemos la solución única:

$$\begin{aligned} \Phi^\top \Phi w &= \Phi^\top t, \\ (\Phi^\top \Phi)^{-1} \Phi^\top \Phi w &= (\Phi^\top \Phi)^{-1} \Phi^\top t, \\ \widehat{w}_{\mathrm{OLS}} &= (\Phi^\top \Phi)^{-1} \Phi^\top t. \end{aligned}$$

Por otro lado, si $\operatorname{rank}(\Phi) < Q$, existe un vector $v \neq 0$ tal que $v \in \ker(\Phi)$. Para cualquier minimizador w_* y escalar $\alpha \in \mathbb{R}$,

$$\Phi(w_* + \alpha v) = \Phi w_* + \alpha \Phi v = \Phi w_*,$$

por lo que $J(w_* + \alpha v) = J(w_*)$. Así se obtienen infinitos minimizadores distintos. El conjunto completo de soluciones es

$$\arg\min_{w \in \mathbb{R}^Q} J(w) = \left\{ \Phi^\dagger t + v : v \in \ker(\Phi) \right\}.$$

Aquí, $\Phi^\dagger t$ es la solución de menor norma y $\Phi^\dagger$ es la pseudoinversa de Moore–Penrose.

1.2 Mínimos cuadrados regularizados

Formulación del problema

Para penalizar pesos de gran magnitud y reducir el sobreajuste, se añade una penalización L_2, con $\lambda > 0$:

$$J_\lambda(w) = \frac{1}{2}\|t - \Phi w\|_2^2 + \frac{\lambda}{2}\|w\|_2^2.$$

Como $\|w\|_2^2 = w^\top w = w^\top I_Q w$, al expandir se obtiene

$$\begin{aligned} J_\lambda(w) &= \frac{1}{2}t^\top t - t^\top \Phi w + \frac{1}{2}w^\top \Phi^\top \Phi w + \frac{\lambda}{2}w^\top I_Q w \\ &= \frac{1}{2}t^\top t - t^\top \Phi w + \frac{1}{2}w^\top (\Phi^\top \Phi + \lambda I_Q) w. \end{aligned}$$

La matriz identidad permite expresar la penalización como un producto cuadrático, $w^\top w = w^\top I_Q w$. Como w tiene Q componentes, I_Q debe ser de dimensión $Q \times Q$. Así, λI_Q y $\Phi^\top \Phi$ tienen la misma dimensión y pueden sumarse; λ es un escalar positivo que controla la intensidad de la regularización.

Si la penalización se define como $\lambda\|w\|_2^2$ sin el factor $1/2$, en las expresiones siguientes se reemplaza λ por 2λ.

Derivación y solución cerrada

La derivada de la pérdida ordinaria se obtuvo en el punto 1.1. Para el término de penalización,

$$\frac{d}{dw}\left(\frac{\lambda}{2}w^\top w\right) = \frac{\lambda}{2}(2w) = \lambda w = \lambda I_Q w.$$

Sumando ambas derivadas,

$$\frac{dJ_\lambda(w)}{dw} = -\Phi^\top t + \Phi^\top \Phi w + \lambda I_Q w = -\Phi^\top t + (\Phi^\top \Phi + \lambda I_Q) w.$$

Al igualar la derivada a cero se obtienen las ecuaciones normales regularizadas:

$$(\Phi^\top \Phi + \lambda I_Q) w = \Phi^\top t.$$

Hessiana, invertibilidad y unicidad

La matriz del sistema regularizado también es la Hessiana del objetivo:

$$H_\lambda = \frac{\partial^2 J_\lambda(w)}{\partial w \, \partial w^\top} = \Phi^\top \Phi + \lambda I_Q.$$

Para cualquier $v \in \mathbb{R}^Q \setminus \{0\}$,

$$\begin{aligned} v^\top H_\lambda v &= \|\Phi v\|_2^2 + \lambda \|v\|_2^2 \\ &> 0, \end{aligned}$$

porque $\|\Phi v\|_2^2 \geq 0$, $\lambda > 0$ y $\|v\|_2^2 > 0$. Por tanto, H_λ es simétrica definida positiva ($H_\lambda \succ 0$), y J_λ es estrictamente convexa.

Además, H_λ es invertible. En efecto, si fuera singular, existiría $v \neq 0$ tal que

$$H_\lambda v = 0 \quad \Longrightarrow \quad v^\top H_\lambda v = 0,$$

lo cual contradice $v^\top H_\lambda v > 0$. Así, la inversa existe para cualquier relación entre N y Q.

Multiplicando las ecuaciones normales regularizadas por H_λ^{-1} a la izquierda, se despeja w:

$$\begin{aligned} H_\lambda w &= \Phi^\top t, \\ H_\lambda^{-1} H_\lambda w &= H_\lambda^{-1} \Phi^\top t, \\ I_Q w &= H_\lambda^{-1} \Phi^\top t, \\ \widehat{w}_{\text{ridge}} &= H_\lambda^{-1} \Phi^\top t = (\Phi^\top \Phi + \lambda I_Q)^{-1} \Phi^\top t. \end{aligned}$$

Como J_λ es estrictamente convexa, este punto crítico es el único mínimo global.

Efecto del parámetro λ

El parámetro $\lambda > 0$ controla el balance entre el ajuste a los datos de entrenamiento y la simplicidad del modelo, medida por la magnitud de los pesos. Su efecto se analiza desde tres perspectivas.

1. Efecto algebraico: estabilidad e invertibilidad. Sean $\{\mu_1, \mu_2, \ldots, \mu_Q\}$ los autovalores de $\Phi^\top \Phi$. Como esta matriz es simétrica y semidefinida positiva,

$$\mu_i \geq 0, \qquad i = 1, \ldots, Q.$$

Al sumar la regularización λI_Q, cada autovalor se desplaza en λ:

$$\text{eig}(\Phi^\top \Phi + \lambda I_Q) = \{\mu_i + \lambda\}_{i=1}^{Q}.$$

En particular,

$$\mu_{\min} + \lambda \geq \lambda > 0.$$

Por ello, ningún autovalor regularizado es cero y $\Phi^\top \Phi + \lambda I_Q$ es definida positiva e invertible, aun cuando $N < Q$ o las columnas de Φ sean linealmente dependientes. Además, su número de condición espectral es

$$\kappa_2(\lambda) = \frac{\mu_{\max} + \lambda}{\mu_{\min} + \lambda}.$$

Al aumentar λ, este cociente disminuye hacia 1, lo que mejora el condicionamiento y reduce la sensibilidad del cálculo ante pequeñas perturbaciones en los datos.

2. Efecto sobre los pesos: contracción y casos límite. La penalización $\frac{\lambda}{2}\|w\|_2^2$ castiga los coeficientes grandes. La solución cerrada es

$$\widehat{w}_{\text{ridge}} = (\Phi^\top \Phi + \lambda I_Q)^{-1} \Phi^\top t.$$

Cuando la regularización desaparece ($\lambda \to 0^+$),

$$\widehat{w}_{\text{ridge}} \longrightarrow \begin{cases} \widehat{w}_{\text{OLS}}, & \text{rank}(\Phi) = Q, \\ \Phi^\dagger t, & \text{rank}(\Phi) < Q. \end{cases}$$

En el segundo caso, esto incluye tanto $N < Q$ como la presencia de redundancia entre las columnas. Cuando la regularización domina ($\lambda \to \infty$),

$$(\Phi^\top \Phi + \lambda I_Q)^{-1} = \frac{1}{\lambda}\left(I_Q + \frac{1}{\lambda}\Phi^\top \Phi\right)^{-1} \longrightarrow 0_{Q\times Q}, \qquad \widehat{w}_{\text{ridge}} \longrightarrow 0_{Q\times 1}.$$

Así, los coeficientes son contraídos hacia cero.

3. Efecto estadístico: compromiso sesgo-varianza. Aumentar λ hace al modelo más rígido y menos sensible al ruido muestral. Esto suele reducir la varianza y el sobreajuste, a costa de introducir sesgo hacia el origen. Disminuir λ reduce ese sesgo y permite un ajuste mayor a los datos de entrenamiento, pero puede aumentar la varianza y el riesgo de sobreajuste. En la práctica, se busca un valor intermedio de λ que minimice el error de generalización en datos no usados para ajustar el modelo.

1.3 Estimador de máxima verosimilitud (MLE)

Modelo probabilístico y función de verosimilitud

Dado el modelo de ruido gaussiano $\eta_n \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma_\eta^2)$, la respuesta condicionada a la entrada, los pesos y la varianza satisface

$$t_n \mid x_n, w, \sigma_\eta^2 \sim \mathcal{N}\Big(\phi(x_n)^\top w, \sigma_\eta^2\Big).$$

Su densidad es

$$p(t_n \mid x_n, w, \sigma_\eta^2) = \frac{1}{\sqrt{2\pi\sigma_\eta^2}} \exp\left(-\frac{(t_n - \phi(x_n)^\top w)^2}{2\sigma_\eta^2}\right).$$

Por la independencia condicional de las observaciones, la verosimilitud conjunta es el producto de las densidades individuales:

$$\begin{aligned} L(w) &= p(t \mid \Phi, w, \sigma_\eta^2) \\ &= \prod_{n=1}^{N} p(t_n \mid x_n, w, \sigma_\eta^2) \\ &= \prod_{n=1}^{N} \left[(2\pi\sigma_\eta^2)^{-1/2} \exp\left(-\frac{(t_n - \phi(x_n)^\top w)^2}{2\sigma_\eta^2}\right)\right] \\ &= \underbrace{\left[\prod_{n=1}^{N} (2\pi\sigma_\eta^2)^{-1/2}\right]}_{\text{producto de constantes}} \underbrace{\left[\prod_{n=1}^{N} \exp\left(-\frac{(t_n - \phi(x_n)^\top w)^2}{2\sigma_\eta^2}\right)\right]}_{\text{producto de exponenciales}}. \end{aligned}$$

En el primer producto se repite la misma constante N veces, así que

$$\begin{aligned} \prod_{n=1}^{N} (2\pi\sigma_\eta^2)^{-1/2} &= \Big((2\pi\sigma_\eta^2)^{-1/2}\Big)^N \\ &= (2\pi\sigma_\eta^2)^{-N/2}. \end{aligned}$$

Para el segundo producto usamos que el producto de exponenciales es la exponencial de la suma de sus exponentes:

$$\prod_{n=1}^{N} \exp\left(-\frac{(t_n - \phi(x_n)^\top w)^2}{2\sigma_\eta^2}\right) = \exp\left(\sum_{n=1}^{N} -\frac{(t_n - \phi(x_n)^\top w)^2}{2\sigma_\eta^2}\right)$$
$$= \exp\left(-\frac{1}{2\sigma_\eta^2}\sum_{n=1}^{N}(t_n - \phi(x_n)^\top w)^2\right).$$

Por la definición de la matriz de diseño, la componente n de Φw es $(\Phi w)_n = \phi(x_n)^\top w$. Por ello, el vector $t - \Phi w$ contiene los residuos $t_n - \phi(x_n)^\top w$, y

$$\sum_{n=1}^{N}(t_n - \phi(x_n)^\top w)^2 = (t - \Phi w)^\top (t - \Phi w) = \|t - \Phi w\|_2^2.$$

Juntando ambos productos y sustituyendo la suma por la norma, obtenemos la forma matricial de la verosimilitud:

$$L(w) = (2\pi\sigma_\eta^2)^{-N/2} \exp\left(-\frac{1}{2\sigma_\eta^2}\|t - \Phi w\|_2^2\right).$$

Log-verosimilitud y relación con OLS

Tomando el logaritmo natural de la verosimilitud se obtiene

$$\ell(w) = \ln L(w) = -\frac{N}{2}\ln(2\pi\sigma_\eta^2) - \frac{1}{2\sigma_\eta^2}\|t - \Phi w\|_2^2.$$

Si $\sigma_\eta^2 > 0$ es fija, el primer término no depende de w y el factor $1/(2\sigma_\eta^2)$ es positivo. Por consiguiente,

$$\arg\max_{w\in\mathbb{R}^Q} \ell(w) = \arg\min_{w\in\mathbb{R}^Q} \frac{1}{2\sigma_\eta^2}\|t - \Phi w\|_2^2$$
$$= \arg\min_{w\in\mathbb{R}^Q} \frac{1}{2}\|t - \Phi w\|_2^2$$
$$= \arg\min_{w\in\mathbb{R}^Q} J(w).$$

Así, bajo el supuesto de ruido gaussiano homocedástico e independiente, maximizar la verosimilitud respecto de w equivale a minimizar la pérdida OLS.

La derivada de la log-verosimilitud es

$$\frac{d\ell(w)}{dw} = \frac{1}{\sigma_\eta^2}\left(\Phi^\top t - \Phi^\top \Phi w\right).$$

Al igualarla a cero y usar $\sigma_\eta^2 > 0$,

$$\Phi^\top \Phi w = \Phi^\top t.$$

Si $\operatorname{rank}(\Phi) = Q$, la matriz $\Phi^\top\Phi$ es invertible y el estimador de máxima verosimilitud es

$$\widehat{w}_{\mathrm{MLE}} = (\Phi^\top\Phi)^{-1}\Phi^\top t = \widehat{w}_{\mathrm{OLS}}.$$

Si $\operatorname{rank}(\Phi) < Q$, el MLE no es único; el conjunto de maximizadores coincide con el conjunto de minimizadores OLS y su elemento de norma mínima es $\Phi^\dagger t$.

1.4 Estimador máximo a posteriori (MAP)

Formulación bayesiana

Se asigna a los pesos un prior gaussiano isotrópico

$$w \sim \mathcal{N}(0, \sigma_w^2 I_Q), \qquad \sigma_w^2 > 0,$$

cuya densidad es

$$p(w) = (2\pi\sigma_w^2)^{-Q/2} \exp\left(-\frac{1}{2\sigma_w^2}\|w\|_2^2\right).$$

La constante de normalización depende de la dimensión Q de w. Por el teorema de Bayes,

$$p(w \mid t, \Phi) = \frac{p(t \mid \Phi, w)p(w)}{p(t \mid \Phi)} \propto p(t \mid \Phi, w)p(w),$$

En esta expresión, cada término tiene una interpretación:

Posterior, $p(w \mid t, \Phi)$**.** Es la densidad de probabilidad posterior de los pesos después de observar las respuestas t y la matriz de diseño Φ. Esta es la cantidad que se maximiza en el estimador MAP.

Verosimilitud, $p(t \mid \Phi, w)$**.** Mide qué tan compatibles son los datos observados con un valor dado de los pesos w, condicionados a Φ. Corresponde a la verosimilitud usada en el punto 1.3.

Prior, $p(w)$**.** Describe la información o creencia previa sobre los pesos antes de observar t. Aquí se usa el prior gaussiano $w \sim \mathcal{N}(0, \sigma_w^2 I_Q)$, que favorece pesos de menor magnitud, aunque no obliga a que sean cero.

Evidencia marginal, $p(t \mid \Phi)$**.** Es la densidad de los datos observados, promediada sobre todos los posibles valores de w según el prior. Como no depende de w, es una constante al buscar el máximo posterior y por eso el posterior es proporcional al producto de la verosimilitud y el prior.

En consecuencia, el estimador MAP busca el vector de pesos que maximiza la densidad posterior. Al omitir el factor $p(t \mid \Phi)$, que es constante respecto de w, se puede escribir

$$\widehat{w}_{\text{MAP}} = \arg\max_{w \in \mathbb{R}^Q} p(w \mid t, \Phi) = \arg\max_{w \in \mathbb{R}^Q} p(t \mid \Phi, w)p(w).$$

Para simplificar este producto, aplicamos el logaritmo natural. Como ln es estrictamente creciente, no cambia el valor de w que maximiza la expresión; además, convierte el producto en una suma:

$$\ln[p(t \mid \Phi, w)p(w)] = \ln p(t \mid \Phi, w) + \ln p(w).$$

Objetivo log-MAP

Como en el punto 1.3, al optimizar respecto de w podemos descartar los sumandos que no dependen de este vector, pues agregar o quitar una constante no cambia el maximizador. Aquí se agrupan

en una constante los factores de normalización gaussianos, como $-\frac{N}{2}\ln(2\pi\sigma_\eta^2)$ y $-\frac{Q}{2}\ln(2\pi\sigma_w^2)$, así como el término $-\ln p(t \mid \Phi)$ de la evidencia marginal. Esto supone que σ_η^2 y σ_w^2 son fijas; si también se estimaran, algunos de esos términos podrían depender de esos parámetros y no se podrían omitir al optimizarlos. Al sustituir las densidades gaussianas, queda

$$\ln p(w \mid t, \Phi) = -\frac{1}{2\sigma_\eta^2}\|t - \Phi w\|_2^2 - \frac{1}{2\sigma_w^2}\|w\|_2^2 + \text{constante}.$$

Multiplicar la expresión que se maximiza por $-\sigma_\eta^2$ equivale a minimizar su opuesto escalado. Por ello, el problema MAP puede escribirse como

$$\widehat{w}_{\text{MAP}} = \underset{w\in\mathbb{R}^Q}{\arg\min}\left[\frac{1}{2}\|t - \Phi w\|_2^2 + \frac{\sigma_\eta^2}{2\sigma_w^2}\|w\|_2^2\right].$$

Solución analítica y correspondencia con Ridge

Derivando el objetivo MAP respecto de w,

$$-\Phi^\top(t - \Phi w) + \frac{\sigma_\eta^2}{\sigma_w^2}w = 0.$$

Reordenando,

$$\left(\Phi^\top\Phi + \frac{\sigma_\eta^2}{\sigma_w^2}I_Q\right)w = \Phi^\top t.$$

Como $\sigma_\eta^2/\sigma_w^2 > 0$, la matriz del lado izquierdo es definida positiva e invertible. Multiplicando ambos lados por su inversa, se obtiene

$$\widehat{w}_{\text{MAP}} = \left(\Phi^\top\Phi + \frac{\sigma_\eta^2}{\sigma_w^2}I_Q\right)^{-1}\Phi^\top t.$$

Al compararla con el estimador Ridge,

$$\widehat{w}_{\text{ridge}} = (\Phi^\top\Phi + \lambda I_Q)^{-1}\Phi^\top t,$$

se identifica la equivalencia

$$\lambda = \frac{\sigma_\eta^2}{\sigma_w^2}.$$

Por tanto, λ es la razón entre la varianza del ruido de las mediciones y la varianza a priori de los pesos. En el límite $\sigma_w^2 \to \infty$, el prior se hace cada vez menos informativo y $\lambda \to 0^+$; se recupera el estimador OLS cuando Φ tiene rango completo, y el límite de norma mínima $\Phi^\dagger t$ si no lo tiene. Si aumenta σ_η^2 o disminuye σ_w^2, aumenta λ y la solución se contrae más hacia cero.

Punto 2. Embedding de media

2.1. Definición rigurosa del embedding de media

El objetivo fundamental del embedding de media es representar la distribución de probabilidad de una variable aleatoria X mediante un único objeto (un punto) en un espacio de Hilbert con núcleo reproductor, denotado por $\mathcal{H}_k$.

Para construir esta representación, partimos de un dominio $\mathcal{X}$ y de un kernel simétrico positivo definido $k : \mathcal{X} \times \mathcal{X} \to \mathbb{R}$. Este kernel induce el mapeo de características

$$\phi_k : \mathcal{X} \to \mathcal{H}_k, \qquad x \mapsto k(x, \cdot).$$

Es importante comprender la notación $\cdot$: no representa una multiplicación, sino una ranura libre que indica el argumento pendiente de la función. Al fijar una observación x, $k(x, \cdot)$ deja de ser un escalar y se convierte en una función de $\mathcal{H}_k$, que puede evaluarse en un segundo punto z como $k(x, z)$.

Sea X una variable aleatoria con distribución P_X. Su embedding de media μ_X se define como el valor esperado de este mapeo de características, suponiendo que la esperanza exista:

$$\mu_X = \mathbb{E}_{X \sim P_X}[k(X, \cdot)].$$

La esperanza no promedia valores escalares en el dominio original $\mathcal{X}$; calcula el centro de masa funcional de las funciones $k(X, \cdot)$ en $\mathcal{H}_k$, ponderadas por la probabilidad de ocurrencia de cada estado.

Caso discreto. Supongamos que X toma r valores distintos $x_1, x_2, \ldots, x_r$, con probabilidades asociadas $p_1, p_2, \ldots, p_r$, donde $\sum_{i=1}^{r} p_i = 1$. En este caso, la esperanza se convierte en una suma ponderada:

$$\mu_X = \sum_{i=1}^{r} p_i \, k(x_i, \cdot).$$

El resultado no es un número aislado, sino una única función combinada que resume la distribución discreta P_X en el RKHS. La representación identifica de manera única la distribución cuando el kernel es característico.

2.2. Propiedades del RKHS y naturaleza geométrica del embedding

Un espacio de Hilbert con núcleo reproductor (RKHS), denotado por $\mathcal{H}_k$, es un espacio de funciones con un producto interno $\langle \cdot, \cdot \rangle_{\mathcal{H}_k}$. Este producto permite medir la similitud entre funciones, y la completitud garantiza que los límites necesarios para trabajar en el espacio siguen perteneciendo a él.

Propiedad reproductora. La propiedad fundamental del RKHS dice que, para toda función $f \in \mathcal{H}_k$ y todo punto $x \in \mathcal{X}$,

$$\langle f, k(x, \cdot) \rangle_{\mathcal{H}_k} = f(x).$$

Por tanto, $k(x, \cdot)$ funciona como una sonda: al calcular su producto interno con f, se obtiene el valor de f en x. En particular,

$$\langle k(y, \cdot), k(x, \cdot) \rangle_{\mathcal{H}_k} = k(y, x) = k(x, y),$$

pues el kernel es simétrico. Así, evaluar el kernel entre dos puntos originales equivale a calcular el producto interno de sus representaciones en el RKHS.

Embedding de media como promedio de funciones. El embedding de media se define como el promedio de las funciones inducidas por las observaciones:

$$\mu_X = \mathbb{E}_{X \sim P_X}[k(X, \cdot)].$$

La esperanza aquí es un promedio de funciones, no solamente de números. Si X toma valores $x_1, \ldots, x_r$ con probabilidades $p_1, \ldots, p_r$, este promedio es la suma ponderada

$$\mu_X = \sum_{i=1}^{r} p_i k(x_i, \cdot).$$

Para una variable continua, se interpreta como la versión integral de ese promedio (o, intuitivamente, como el límite de promedios ponderados). El nombre técnico de esta construcción es esperanza o integral de Bochner; no es un espacio adicional que se deba conocer para entender las propiedades que siguen.

Una propiedad útil del embedding se obtiene al combinar la linealidad del producto interno con la propiedad reproductora:

$$\begin{aligned} \langle f, \mu_X \rangle_{\mathcal{H}_k} &= \mathbb{E}_{X \sim P_X}[\langle f, k(X, \cdot) \rangle_{\mathcal{H}_k}] \\ &= \mathbb{E}_{X \sim P_X}[f(X)], \qquad f \in \mathcal{H}_k. \end{aligned}$$

Es decir, el embedding permite obtener la esperanza de cualquier función del RKHS mediante un producto interno.

Pertenencia al RKHS. La propiedad reproductora implica que

$$\|k(x, \cdot)\|^2_{\mathcal{H}_k} = k(x, x).$$

Por ello, una condición suficiente para que el promedio poblacional esté bien definido y pertenezca a $\mathcal{H}_k$ es

$$\mathbb{E}_{X \sim P_X}[\sqrt{k(X, X)}] < \infty.$$

En particular, esto se cumple si existe una constante $C < \infty$ tal que $k(x, x) \leq C$ para todo x. En ese caso,

$$\|\mu_X\|_{\mathcal{H}_k} \leq \mathbb{E}_{X \sim P_X}[\sqrt{k(X, X)}] \leq \sqrt{C}.$$

Por ejemplo, para el kernel gaussiano $k(x, x') = \exp(-\gamma \|x - x'\|_2^2)$, con $\gamma > 0$, se tiene $k(x, x) = 1$, así que la condición se cumple para cualquier distribución.

Para una muestra finita $x_1, \ldots, x_n$, el embedding empírico es

$$\widehat{\mu}_X = \frac{1}{n} \sum_{i=1}^{n} k(x_i, \cdot).$$

Cada término pertenece al RKHS y una combinación lineal finita de sus elementos también; por tanto, $\widehat{\mu}_X \in \mathcal{H}_k$.

Interpretación geométrica. Geométricamente, μ_X es el centroide o promedio de las funciones $k(X, \cdot)$ en el RKHS. Cada distribución queda representada por un punto, y la norma $\|\mu_X - \mu_Y\|_{\mathcal{H}_k}$ mide la distancia entre las representaciones de dos distribuciones. Si el kernel es característico, esa representación distingue todas las distribuciones:

$$\mu_X = \mu_Y \quad \Longleftrightarrow \quad P_X = P_Y.$$

Esta propiedad depende de que el kernel sea característico; no se cumple automáticamente para cualquier kernel.

2.3. Discrepancia Máxima de Medias (MMD)

Sean P_X y P_Y dos distribuciones sobre el mismo dominio $\mathcal{X}$, y supongamos que sus embeddings de media existen en el mismo RKHS $\mathcal{H}_k$. La discrepancia máxima de medias (MMD) es la distancia entre esos embeddings:

$$\mathrm{MMD}^2(P_X, P_Y) = \|\mu_X - \mu_Y\|^2_{\mathcal{H}_k}.$$

El cuadrado evita escribir una raíz y permite expresar la distancia usando únicamente evaluaciones del kernel.

Formulación poblacional. Al expandir la norma mediante el producto interno,

$$\mathrm{MMD}^2(P_X, P_Y) = \langle \mu_X, \mu_X \rangle_{\mathcal{H}_k} + \langle \mu_Y, \mu_Y \rangle_{\mathcal{H}_k} - 2\langle \mu_X, \mu_Y \rangle_{\mathcal{H}_k}.$$

Sean X, X' copias independientes con distribución P_X, y Y, Y' copias independientes con distribución P_Y. Además, tomamos independiente una variable con distribución P_X de otra con distribución P_Y. Usando la propiedad reproductora $\langle k(u, \cdot), k(v, \cdot) \rangle_{\mathcal{H}_k} = k(u, v)$, cada término se convierte en una esperanza de valores del kernel:

$$\begin{aligned}
\langle \mu_X, \mu_X \rangle_{\mathcal{H}_k} &= \mathbb{E}[k(X, X')], \\
\langle \mu_Y, \mu_Y \rangle_{\mathcal{H}_k} &= \mathbb{E}[k(Y, Y')], \\
\langle \mu_X, \mu_Y \rangle_{\mathcal{H}_k} &= \mathbb{E}[k(X, Y)].
\end{aligned}$$

Por tanto, la expresión poblacional es

$$\boxed{\mathrm{MMD}^2(P_X, P_Y) = \mathbb{E}[k(X, X')] + \mathbb{E}[k(Y, Y')] - 2\mathbb{E}[k(X, Y)]}.$$

Estimador empírico y sesgo. Sean $x_1, \ldots, x_n$ una muestra i.i.d. de P_X y $y_1, \ldots, y_m$ una muestra i.i.d. de P_Y, independientes entre sí. Sus embeddings empíricos son

$$\widehat{\mu}_X = \frac{1}{n}\sum_{i=1}^{n} k(x_i, \cdot), \qquad \widehat{\mu}_Y = \frac{1}{m}\sum_{j=1}^{m} k(y_j, \cdot).$$

Al calcular $\|\widehat{\mu}_X - \widehat{\mu}_Y\|^2_{\mathcal{H}_k}$ y aplicar la propiedad reproductora se obtiene el estimador sesgado (también llamado estimador V):

$$\widehat{\mathrm{MMD}}_b^2 = \frac{1}{n^2}\sum_{i=1}^{n}\sum_{j=1}^{n} k(x_i, x_j) + \frac{1}{m^2}\sum_{i=1}^{m}\sum_{j=1}^{m} k(y_i, y_j) - \frac{2}{nm}\sum_{i=1}^{n}\sum_{j=1}^{m} k(x_i, y_j).$$

Se llama sesgado porque las sumas dentro de cada muestra incluyen la diagonal, por ejemplo $k(x_i, x_i)$. Para muestras i.i.d., su esperanza es

$$\mathbb{E}[\widehat{\mathrm{MMD}}_b^2] = \mathrm{MMD}^2(P_X, P_Y) + \frac{\mathbb{E}[k(X,X)] - \mathbb{E}[k(X,X')]}{n} + \frac{\mathbb{E}[k(Y,Y)] - \mathbb{E}[k(Y,Y')]}{m}.$$

Los dos términos adicionales son no negativos para un kernel positivo definido; por ello, el estimador tiene sesgo positivo. El estimador es una norma al cuadrado entre embeddings empíricos y nunca es negativo. Aun cuando $P_X = P_Y$, suele ser positivo con muestras finitas; puede ser cero si los embeddings empíricos coinciden.

Una alternativa insesgada, que requiere $n, m \geq 2$, excluye las diagonales de las sumas dentro de cada muestra:

$$\widehat{\mathrm{MMD}}_u^2 = \frac{1}{n(n-1)}\sum_{i\neq j} k(x_i, x_j) + \frac{1}{m(m-1)}\sum_{i\neq j} k(y_i, y_j) - \frac{2}{nm}\sum_{i=1}^{n}\sum_{j=1}^{m} k(x_i, y_j).$$

Este estimador tiene esperanza igual a la MMD poblacional al cuadrado, pero puede tomar valores negativos en una muestra particular.

Formulación matricial. Definimos las matrices de Gram

$$(K_{XX})_{ij} = k(x_i, x_j), \qquad (K_{YY})_{ij} = k(y_i, y_j), \qquad (K_{XY})_{ij} = k(x_i, y_j),$$

con dimensiones $K_{XX} \in \mathbb{R}^{n\times n}$, $K_{YY} \in \mathbb{R}^{m\times m}$ y $K_{XY} \in \mathbb{R}^{n\times m}$. Sean $\mathbf{1}_n \in \mathbb{R}^{n\times 1}$ y $\mathbf{1}_m \in \mathbb{R}^{m\times 1}$ vectores cuyas entradas son todas iguales a uno. Para cualquier matriz $A \in \mathbb{R}^{n\times m}$,

$$\mathbf{1}_n^\top A \mathbf{1}_m = \sum_{i=1}^{n}\sum_{j=1}^{m} A_{ij}.$$

En efecto, la componente i del vector $A\mathbf{1}_m$ es la suma de la fila i; al multiplicar por $\mathbf{1}_n^\top$ se suman esas filas. Así, cada doble suma del estimador puede escribirse como un producto matricial, y se obtiene

$$\boxed{\widehat{\mathrm{MMD}}_b^2 = \frac{1}{n^2}\mathbf{1}_n^\top K_{XX}\mathbf{1}_n + \frac{1}{m^2}\mathbf{1}_m^\top K_{YY}\mathbf{1}_m - \frac{2}{nm}\mathbf{1}_n^\top K_{XY}\mathbf{1}_m}.$$

Por ejemplo, $\mathbf{1}_n^\top K_{XX}\mathbf{1}_n$ tiene dimensiones $(1\times n)(n\times n)(n\times 1)$ y, por tanto, es un escalar; los otros dos términos también son escalares.

2.4. Metodología de validación: MNIST vs. Fashion-MNIST

Cada imagen de 28×28 píxeles se aplana en un vector de dimensión 784 y se normaliza dividiendo sus intensidades por 255, de modo que $x_{\text{norm}} \in [0,1]^{784}$. Se fija una semilla aleatoria para seleccionar 1000 imágenes de cada conjunto de datos y se separan en dos submuestras disjuntas de 500 imágenes. Las submuestras permiten hacer comparaciones dentro de un mismo conjunto y entre conjuntos.

Se utiliza el kernel gaussiano (RBF)

$$k(u,v) = \exp\left(-\frac{\|u-v\|_2^2}{2\sigma^2}\right), \qquad \sigma > 0.$$

El parámetro σ controla cuánto disminuye la similitud al aumentar la distancia entre dos imágenes. Como valor inicial se puede usar la heurística de la mediana: calcular las distancias euclidianas entre pares de imágenes de la muestra combinada y tomar su mediana como σ. Se emplea el mismo valor en todas las comparaciones para mantener el mismo kernel. Esta regla práctica ayuda a elegir la escala, pero no reemplaza una evaluación estadística.

Con $n = m = 500$, las matrices K_{XX}, K_{YY} y K_{XY} son todas de dimensión 500×500, y la MMD empírica se calcula con la fórmula matricial anterior. Se consideran, por ejemplo, las comparaciones entre dos submuestras de MNIST, entre dos de Fashion-MNIST y entre una de cada conjunto. Las comparaciones MNIST_1 vs. MNIST_2 y Fashion-MNIST_1 vs. Fashion-MNIST_2 sirven como controles bajo la hipótesis nula $H_0 : P_X = P_Y$. En cambio, MNIST vs. Fashion-MNIST es la comparación de interés bajo la alternativa $H_1 : P_X \neq P_Y$. Bajo H_0, la MMD poblacional es cero, aunque la estimación sesgada con muestras finitas puede ser positiva. Se espera que las comparaciones de control sean menores, en promedio, que la comparación entre conjuntos, pero la magnitud observada por sí sola no demuestra una diferencia significativa.

Para evaluar la diferencia se puede realizar una prueba de permutaciones. Se combinan las muestras, se permutan aleatoriamente sus etiquetas manteniendo los tamaños de grupo y se recalcula la MMD en cada una de las B permutaciones. Si T_{obs} es el valor observado y $T_1, \ldots, T_B$ son los valores permutados, un valor p empírico de cola superior es

$$\widehat{p} = \frac{1 + \sum_{b=1}^{B} \mathbf{1}\{T_b \geq T_{\text{obs}}\}}{B+1}.$$

La conclusión sobre si las distribuciones difieren debe basarse en esta prueba y no únicamente en que la MMD empírica sea positiva.

Punto 3. Correlación de Pearson y alineamiento de kernels

3.1. Derivación matricial de la correlación de Pearson

Objetivo. Expresar la correlación de Pearson mediante operaciones matriciales. Esta medida indica qué tan fuerte es la relación lineal entre dos variables y en qué dirección ocurre: positiva, negativa o nula.

Paso 1: definición poblacional y estimador muestral. Para variables aleatorias X e Y con varianzas positivas, el coeficiente de correlación poblacional de Pearson se define como

$$\rho_{XY} = \frac{\mathbb{E}[(X-\mu_X)(Y-\mu_Y)]}{\sqrt{\mathbb{E}[(X-\mu_X)^2]\mathbb{E}[(Y-\mu_Y)^2]}},$$

donde $\mu_X = \mathbb{E}[X]$ y $\mu_Y = \mathbb{E}[Y]$. Para una muestra finita de N observaciones emparejadas $\{(x_i, y_i)\}_{i=1}^N$, aproximamos las esperanzas por promedios muestrales y usamos las medias muestrales

$$\bar{x} = \frac{1}{N}\sum_{i=1}^N x_i, \qquad \bar{y} = \frac{1}{N}\sum_{i=1}^N y_i.$$

Así, el estimador muestral es

$$\hat{\rho}_{XY} = \frac{\frac{1}{N}\sum_{i=1}^N (x_i-\bar{x})(y_i-\bar{y})}{\sqrt{\left(\frac{1}{N}\sum_{i=1}^N (x_i-\bar{x})^2\right)\left(\frac{1}{N}\sum_{i=1}^N (y_i-\bar{y})^2\right)}}.$$

Los factores $1/N$ se cancelan: el denominador contiene $\sqrt{(1/N)(1/N)} = 1/N$, igual que el factor del numerador. Por tanto, la fórmula equivalente es

$$\hat{\rho}_{XY} = \frac{\sum_{i=1}^N (x_i-\bar{x})(y_i-\bar{y})}{\sqrt{\left(\sum_{i=1}^N (x_i-\bar{x})^2\right)\left(\sum_{i=1}^N (y_i-\bar{y})^2\right)}}.$$

Paso 2: vectores de datos, medias y centrado. Representamos las observaciones y el vector de unos como columnas:

$$x = \begin{bmatrix} x_1 & x_2 & \cdots & x_N \end{bmatrix}^\top, \qquad y = \begin{bmatrix} y_1 & y_2 & \cdots & y_N \end{bmatrix}^\top, \qquad \mathbf{1}_N = \begin{bmatrix} 1 & 1 & \cdots & 1 \end{bmatrix}^\top,$$

con $x, y, \mathbf{1}_N \in \mathbb{R}^{N\times 1}$. Las medias pueden escribirse como escalares mediante

$$\bar{x} = \frac{1}{N}\mathbf{1}_N^\top x, \qquad \bar{y} = \frac{1}{N}\mathbf{1}_N^\top y,$$

pues $\mathbf{1}_N^\top x = \sum_{i=1}^N x_i$ y $\mathbf{1}_N^\top y = \sum_{i=1}^N y_i$. Al multiplicar cada media por el vector de unos se obtiene el vector cuyas entradas son esa media:

$$\bar{x}\mathbf{1}_N = \left(\frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top\right)x, \qquad \bar{y}\mathbf{1}_N = \left(\frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top\right)y.$$

Por consiguiente, los vectores centrados son

$$x_c = x - \bar{x}\mathbf{1}_N = \left(I_N - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top\right)x,$$
$$y_c = y - \bar{y}\mathbf{1}_N = \left(I_N - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top\right)y.$$

Definimos entonces la matriz de centrado

$$H = I_N - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top \in \mathbb{R}^{N\times N},$$

de modo que $x_c = Hx$ y $y_c = Hy$. En particular,

$$Hx = \begin{bmatrix} x_1 - \bar{x} \\ x_2 - \bar{x} \\ \vdots \\ x_N - \bar{x} \end{bmatrix}, \qquad Hy = \begin{bmatrix} y_1 - \bar{y} \\ y_2 - \bar{y} \\ \vdots \\ y_N - \bar{y} \end{bmatrix}.$$

Paso 3: propiedades de la matriz de centrado. Primero, H es simétrica:

$$\begin{aligned} H^\top &= \left(I_N - \frac{1}{N} \mathbf{1}_N \mathbf{1}_N^\top \right)^\top \\ &= I_N - \frac{1}{N} (\mathbf{1}_N \mathbf{1}_N^\top)^\top \\ &= I_N - \frac{1}{N} \mathbf{1}_N \mathbf{1}_N^\top \\ &= H. \end{aligned}$$

Además, $\mathbf{1}_N^\top \mathbf{1}_N = N$, porque el producto suma las N entradas iguales a uno. Con esto se demuestra que H es idempotente:

$$\begin{aligned} H^2 &= \left(I_N - \frac{1}{N} \mathbf{1}_N \mathbf{1}_N^\top \right) \left(I_N - \frac{1}{N} \mathbf{1}_N \mathbf{1}_N^\top \right) \\ &= I_N - \frac{2}{N} \mathbf{1}_N \mathbf{1}_N^\top + \frac{1}{N^2} \mathbf{1}_N (\mathbf{1}_N^\top \mathbf{1}_N) \mathbf{1}_N^\top \\ &= I_N - \frac{2}{N} \mathbf{1}_N \mathbf{1}_N^\top + \frac{1}{N} \mathbf{1}_N \mathbf{1}_N^\top \\ &= I_N - \frac{1}{N} \mathbf{1}_N \mathbf{1}_N^\top \\ &= H, \end{aligned}$$

Por tanto, $H^\top H = H^2 = H$ y centrar dos veces no cambia el resultado: $H(Hx) = Hx$ y $H(Hy) = Hy$. En consecuencia, H es la matriz de proyección ortogonal sobre el subespacio de vectores centrados.

Derivación del numerador. La suma de productos entre dos listas de valores se representa mediante el producto punto. Por ejemplo, si

$$a = \begin{bmatrix} a_1 \\ a_2 \\ a_3 \end{bmatrix}, \qquad b = \begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix},$$

ambos son vectores columna de dimensión 3×1, por lo que no se pueden multiplicar directamente como ab. En cambio, al transponer el primero, las dimensiones son compatibles y el resultado es un escalar:

$$a^\top b = \begin{bmatrix} a_1 & a_2 & a_3 \end{bmatrix} \begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix} = a_1 b_1 + a_2 b_2 + a_3 b_3 = \sum_{i=1}^{3} a_i b_i.$$

En general, para $a, b \in \mathbb{R}^{N\times 1}$,

$$a^\top b = \sum_{i=1}^{N} a_i b_i, \qquad (1\times N)(N\times 1) = 1\times 1.$$

En el numerador de Pearson, los vectores columna cuyos componentes se multiplican son precisamente los vectores centrados:

$$a = Hx = x_c, \qquad b = Hy = y_c.$$

Por la regla del producto punto recién explicada,

$$\sum_{i=1}^{N}(x_i - \bar{x})(y_i - \bar{y}) = (Hx)^\top (Hy).$$

Ahora escribimos este producto en términos de x, y y H:

$$\begin{aligned}(Hx)^\top (Hy) &= x^\top H^\top H y \\ &= x^\top H H y.\end{aligned}$$

Usando $H^\top = H$ y luego $H^2 = H$, se obtiene

$$(Hx)^\top (Hy) = x^\top H^2 y = x^\top H y.$$

Por tanto, queda demostrada la transformación del numerador:

$$\sum_{i=1}^{N}(x_i - \bar{x})(y_i - \bar{y}) = x^\top H y.$$

Derivación del denominador. Para la primera suma de cuadrados centrados, escribimos la suma como la norma al cuadrado del vector centrado y desarrollamos el producto:

$$\begin{aligned}\sum_{i=1}^{N}(x_i - \bar{x})^2 &= (Hx)^\top (Hx) \\ &= x^\top H^\top H x \\ &= x^\top H^2 x \\ &= x^\top H x.\end{aligned}$$

En la tercera igualdad usamos $H^\top = H$ y en la última, $H^2 = H$. Análogamente, para la segunda variable:

$$\begin{aligned}\sum_{i=1}^{N}(y_i - \bar{y})^2 &= (Hy)^\top (Hy) \\ &= y^\top H^\top H y \\ &= y^\top H^2 y \\ &= y^\top H y.\end{aligned}$$

Así, el producto de las dos sumas de cuadrados que aparece dentro de la raíz del denominador es

$$\left(\sum_{i=1}^{N}(x_i - \bar{x})^2\right)\left(\sum_{i=1}^{N}(y_i - \bar{y})^2\right) = (x^\top H x)(y^\top H y).$$

Resultado de la transformación. Sustituyendo la expresión obtenida para el numerador y las dos expresiones para las sumas de cuadrados en la definición original, resulta:

$$\boxed{\hat{\rho}_{XY} = \frac{x^\top H y}{\sqrt{(x^\top H x)(y^\top H y)}}}$$

Esta expresión es equivalente a la fórmula original, pero utiliza operaciones matriciales. Se supone que x e y no son constantes, de modo que $x^\top H x > 0$ y $y^\top H y > 0$ y la correlación está definida.

Verificación de dimensiones. Los vectores de observaciones y el vector de unos tienen dimensión $N \times 1$, mientras que sus transpuestas tienen dimensión $1 \times N$:

$$x, y, \mathbf{1}_N \in \mathbb{R}^{N\times 1}, \qquad x^\top, y^\top, \mathbf{1}_N^\top \in \mathbb{R}^{1\times N}.$$

En la definición de H, el producto $\mathbf{1}_N \mathbf{1}_N^\top$ tiene dimensión $(N \times 1)(1 \times N) = N \times N$, por lo que se puede restar de $I_N \in \mathbb{R}^{N\times N}$ y $H \in \mathbb{R}^{N\times N}$. En el numerador matricial,

$$(1 \times N)(N \times N)(N \times 1) = 1 \times 1, \qquad x^\top H y \in \mathbb{R}.$$

De igual manera, los términos del denominador son escalares:

$$(1 \times N)(N \times N)(N \times 1) = 1 \times 1, \qquad x^\top H x,\ y^\top H y \in \mathbb{R}.$$

Por consiguiente, la expresión matricial de $\hat{\rho}_{XY}$ está bien definida y es escalar.

3.2. Alineamiento de kernels centrados

Objetivo. Generalizar la comparación entre variables mediante matrices kernel. A diferencia del punto anterior, donde trabajamos directamente con vectores de observaciones, ahora comparamos matrices que representan similitudes entre pares de datos.

Sean X e Y dos conjuntos de N observaciones, y sean k_X y k_Y sus kernels. Las matrices de Gram asociadas son

$$K_X, K_Y \in \mathbb{R}^{N\times N}, \qquad [K_X]_{ij} = k_X(x_i, x_j), \qquad [K_Y]_{ij} = k_Y(y_i, y_j),$$

donde cada entrada representa la similitud entre un par de observaciones.

Centrado de las matrices. Centramos ambas matrices mediante:

$$K_{X,c} = H K_X H, \qquad K_{Y,c} = H K_Y H.$$

La multiplicación por H a izquierda y derecha centra las filas y las columnas de cada matriz de Gram, eliminando las medias en el espacio de características.

Como las matrices de Gram de kernels simétricos cumplen $K_X^\top = K_X$ y $K_Y^\top = K_Y$, las matrices centradas también son simétricas. En efecto,

$$\begin{aligned} K_{X,c}^\top &= (HK_XH)^\top \\ &= H^\top K_X^\top H^\top \\ &= HK_XH \\ &= K_{X,c}. \end{aligned}$$

De igual manera, $K_{Y,c}^\top = K_{Y,c}$. Además, si K_X es semidefinida positiva, también lo es $K_{X,c}$, pues para cualquier $z \in \mathbb{R}^N$,

$$z^\top K_{X,c} z = z^\top HK_XHz = (Hz)^\top K_X(Hz) \geq 0.$$

El mismo argumento aplica a $K_{Y,c}$.

Producto interno de Frobenius. Para $A, B \in \mathbb{R}^{N\times N}$, el producto interno de Frobenius suma los productos de las entradas correspondientes:

$$\langle A, B\rangle_F = \sum_{i=1}^{N}\sum_{j=1}^{N} A_{ij}B_{ij} = \operatorname{tr}(A^\top B),$$

La última igualdad se obtiene al escribir la traza por componentes:

$$\operatorname{tr}(A^\top B) = \sum_{i=1}^{N}(A^\top B)_{ii} = \sum_{i=1}^{N}\sum_{j=1}^{N} A_{ji}B_{ji} = \sum_{i=1}^{N}\sum_{j=1}^{N} A_{ij}B_{ij}.$$

Aquí, tr es la suma de los elementos de la diagonal de una matriz.

La norma inducida por este producto interno es:

$$\|A\|_F = \sqrt{\langle A, A\rangle_F} = \sqrt{\operatorname{tr}(A^\top A)}.$$

Paso 3: definición y desarrollo del alineamiento. El alineamiento normalizado de los kernels centrados se define como el producto interno de Frobenius entre ellos, dividido por el producto de sus normas:

$$\rho_{\text{RKHS}} = \frac{\langle K_{X,c}, K_{Y,c}\rangle_F}{\|K_{X,c}\|_F \|K_{Y,c}\|_F}.$$

Usando las definiciones del producto interno y de la norma de Frobenius, esta expresión equivale a

$$\rho_{\text{RKHS}} = \frac{\operatorname{tr}(K_{X,c}^\top K_{Y,c})}{\sqrt{\operatorname{tr}(K_{X,c}^\top K_{X,c})\operatorname{tr}(K_{Y,c}^\top K_{Y,c})}}.$$

Como acabamos de demostrar que las matrices centradas son simétricas, $K_{X,c}^\top = K_{X,c}$ y $K_{Y,c}^\top = K_{Y,c}$. Entonces,

$$\rho_{\text{RKHS}} = \frac{\operatorname{tr}(K_{X,c}K_{Y,c})}{\sqrt{\operatorname{tr}(K_{X,c}^2)\operatorname{tr}(K_{Y,c}^2)}}.$$

Desarrollamos primero el numerador sustituyendo $K_{X,c} = HK_XH$ y $K_{Y,c} = HK_YH$:

$$\begin{aligned}\operatorname{tr}(K_{X,c}K_{Y,c}) &= \operatorname{tr}\big((HK_XH)(HK_YH)\big)\\ &= \operatorname{tr}(HK_XH^2K_YH)\\ &= \operatorname{tr}(HK_XHK_YH)\\ &= \operatorname{tr}(K_XHK_YH^2)\\ &= \operatorname{tr}(K_XHK_YH).\end{aligned}$$

En la segunda igualdad agrupamos los dos factores H consecutivos y usamos $H^2 = H$. En la cuarta igualdad usamos la propiedad cíclica de la traza, $\operatorname{tr}(AB) = \operatorname{tr}(BA)$, para mover el primer factor H al final; en la última volvemos a usar $H^2 = H$.

Para el primer término del denominador desarrollamos de la misma manera:

$$\begin{aligned}\operatorname{tr}(K_{X,c}^2) &= \operatorname{tr}\big((HK_XH)(HK_XH)\big)\\ &= \operatorname{tr}(HK_XH^2K_XH)\\ &= \operatorname{tr}(HK_XHK_XH)\\ &= \operatorname{tr}(K_XHK_XH^2)\\ &= \operatorname{tr}(K_XHK_XH).\end{aligned}$$

Análogamente, para el segundo término:

$$\begin{aligned}\operatorname{tr}(K_{Y,c}^2) &= \operatorname{tr}\big((HK_YH)(HK_YH)\big)\\ &= \operatorname{tr}(HK_YH^2K_YH)\\ &= \operatorname{tr}(HK_YHK_YH)\\ &= \operatorname{tr}(K_YHK_YH^2)\\ &= \operatorname{tr}(K_YHK_YH).\end{aligned}$$

Sustituyendo los tres resultados en la definición del alineamiento, obtenemos

$$\boxed{\rho_{\mathrm{RKHS}} = \frac{\operatorname{tr}(K_XHK_YH)}{\sqrt{\operatorname{tr}(K_XHK_XH)\operatorname{tr}(K_YHK_YH)}}}$$

Esta medida indica qué tan parecidos son los patrones de similitud representados por los dos kernels. La normalización permite compararlos sin depender directamente de la magnitud de sus matrices. Los objetos $H, K_X, K_Y, K_{X,c}, K_{Y,c}$ tienen dimensión $N \times N$; los productos que aparecen dentro de las trazas también son $N \times N$, y cada traza es un escalar. Si las matrices centradas no son nulas, las normas del denominador son positivas. Por la desigualdad de Cauchy–Schwarz para el producto de Frobenius, el valor absoluto del alineamiento no supera 1; como ambas matrices centradas son semidefinidas positivas, su producto interno es no negativo. Por tanto, $0 \leq \rho_{\mathrm{RKHS}} \leq 1$ para kernels positivos definidos.

Paso 4: caso lineal escalar y relación con Pearson. Supongamos que $x, y \in \mathbb{R}^{N\times 1}$ son observaciones escalares. El kernel lineal es el producto entre dos observaciones, de modo que

$$k_X(x_i, x_j) = x_ix_j \quad \Longrightarrow \quad K_X = xx^\top, \qquad k_Y(y_i, y_j) = y_iy_j \quad \Longrightarrow \quad K_Y = yy^\top.$$

Al centrar estas matrices,

$$\begin{aligned} K_{X,c} &= HK_XH \\ &= Hxx^\top H \\ &= (Hx)(Hx)^\top, \end{aligned}$$

donde la última igualdad usa $H^\top = H$. De la misma forma, $K_{Y,c} = (Hy)(Hy)^\top$.

Desarrollamos el numerador de la fórmula de alineamiento ya obtenida:

$$\begin{aligned} \operatorname{tr}(K_XHK_YH) &= \operatorname{tr}\big((xx^\top)H(yy^\top)H\big) \\ &= \operatorname{tr}\big(x(x^\top Hy)y^\top H\big) \\ &= (x^\top Hy)\operatorname{tr}(xy^\top H) \\ &= (x^\top Hy)\operatorname{tr}(y^\top Hx) \\ &= (x^\top Hy)(y^\top Hx). \end{aligned}$$

En la segunda igualdad, $x^\top Hy$ es un escalar y puede agruparse entre los factores. En la cuarta usamos la propiedad cíclica de la traza. Además, $y^\top Hx$ es un escalar, por lo que es igual a su transpuesta:

$$y^\top Hx = (y^\top Hx)^\top = x^\top H^\top y = x^\top Hy.$$

Por consiguiente,

$$\operatorname{tr}(K_XHK_YH) = (x^\top Hy)^2.$$

Para el primer término del denominador:

$$\begin{aligned} \operatorname{tr}(K_XHK_XH) &= \operatorname{tr}\big((xx^\top)H(xx^\top)H\big) \\ &= \operatorname{tr}\big(x(x^\top Hx)x^\top H\big) \\ &= (x^\top Hx)\operatorname{tr}(xx^\top H) \\ &= (x^\top Hx)\operatorname{tr}(x^\top Hx) \\ &= (x^\top Hx)(x^\top Hx) \\ &= (x^\top Hx)^2. \end{aligned}$$

En la tercera igualdad sacamos $x^\top Hx$, que es un escalar, fuera de la traza. En la siguiente usamos la propiedad cíclica $\operatorname{tr}(xx^\top H) = \operatorname{tr}(x^\top Hx)$. La expresión $x^\top Hx$ es una matriz 1×1, es decir, un escalar; la traza de una matriz 1×1 es ese mismo escalar. Por eso, en el paso siguiente la traza desaparece y queda $(x^\top Hx)^2$.

La misma cuenta para y da

$$\operatorname{tr}(K_YHK_YH) = (y^\top Hy)^2.$$

Además, H es la matriz de centrado, por lo que $H^\top = H$ y $H^2 = H$. Esto explica el segundo factor H en la igualdad

$$\|Hx\|_2^2 = (Hx)^\top(Hx) = x^\top H^\top Hx = x^\top H^2 x = x^\top Hx.$$

El primer H aparece al transponer el primer factor Hx; el segundo proviene del segundo factor Hx. La simetría y la idempotencia de H permiten reducir su producto a un solo H. De igual manera,

$\|Hy\|_2^2 = y^\top Hy$. Cuando los datos no son constantes, estas cantidades son positivas y la raíz del denominador queda

$$\sqrt{(x^\top Hx)^2(y^\top Hy)^2} = (x^\top Hx)(y^\top Hy).$$

Sustituyendo numerador y denominador en la definición del alineamiento,

$$\begin{aligned}\rho_{\text{RKHS}} &= \frac{(x^\top Hy)^2}{(x^\top Hx)(y^\top Hy)} \\ &= \left(\frac{x^\top Hy}{\sqrt{(x^\top Hx)(y^\top Hy)}}\right)^2 \\ &= \hat{\rho}_{XY}^2.\end{aligned}$$

Así, para kernels lineales sobre variables escalares, el alineamiento es el cuadrado de la correlación de Pearson.

Paso 5: pérdida del signo. La correlación de Pearson puede ser positiva o negativa, según la dirección de la relación lineal. Al elevarla al cuadrado, el alineamiento no conserva esa dirección:

$$\hat{\rho}_{XY} = 0.8 \quad \Longrightarrow \quad \rho_{\text{RKHS}} = (0.8)^2 = 0.64, \qquad \hat{\rho}_{XY} = -0.8 \quad \Longrightarrow \quad \rho_{\text{RKHS}} = (-0.8)^2 = 0.64.$$

En particular, si $y = -x$, entonces

$$K_Y = yy^\top = (-x)(-x)^\top = xx^\top = K_X.$$

Aunque la relación entre las variables es perfectamente negativa, ambas matrices de Gram son idénticas y su alineamiento centrado es 1. El alineamiento compara la estructura de similitudes entre pares de observaciones, no el signo de la relación entre sus valores.