Taller: Clasificación supervisada, vecinos cercanos y evaluación de modelos

Teoría de Aprendizaje de Máquina – 2026-2

Santiago Galeano Castaño
Universidad Nacional de Colombia

9 de noviembre de 2026

Profesor: Diego Armando Pérez Rosero

Índice

1. Clasificación lineal y algoritmo del perceptrón **2**
1.1. 1.1. Frontera de decisión 2
1.2. 1.2. Actualización del perceptrón y cambio del margen 3
1.3. 1.3. Ejercicio numérico 3

2. Clasificación por los k vecinos más cercanos (k-NN) **4**
2.1. 2.1. Cálculo manual de distancias 4
2.2. 2.2. Implementación y evaluación con `make_moons` 5
2.3. 2.3. Interpretación de los resultados 6

3. Evaluación de un clasificador binario **7**
3.1. 3.1. Matriz de confusión 7
3.2. 3.2. Cálculo e interpretación de métricas 7
3.3. 3.3. Verificación con scikit-learn y limitaciones de Accuracy 8

4. Conclusiones **9**

1. Clasificación lineal y algoritmo del perceptrón

1.1. 1.1. Frontera de decisión

El clasificador asigna una clase según el signo de la expresión

$$f(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + b.$$

Con $\mathbf{w} = [1, 2]^\top$ y $b = -3$, la frontera se obtiene igualando esta expresión a cero:

$$\mathbf{w}^\top \mathbf{x} + b = 0 \quad \Longrightarrow \quad x_1 + 2x_2 - 3 = 0.$$

Despejando x_2, resulta

$$\boxed{x_2 = \frac{3 - x_1}{2}}.$$

Esta recta divide el plano en dos regiones. Si $x_1 + 2x_2 - 3 > 0$, la predicción es $+1$; si el resultado es menor o igual que cero, la predicción es -1.

Para clasificar cada observación, se reemplazan sus coordenadas en la función de decisión:

$$\begin{aligned}
\mathbf{x}_1 = (0,0): &\quad 1(0) + 2(0) - 3 = -3 \leq 0 &&\Rightarrow \hat{y}_1 = -1,\\
\mathbf{x}_2 = (1,0): &\quad 1(1) + 2(0) - 3 = -2 \leq 0 &&\Rightarrow \hat{y}_2 = -1,\\
\mathbf{x}_3 = (2,1): &\quad 1(2) + 2(1) - 3 = 1 > 0 &&\Rightarrow \hat{y}_3 = +1,\\
\mathbf{x}_4 = (3,1): &\quad 1(3) + 2(1) - 3 = 2 > 0 &&\Rightarrow \hat{y}_4 = +1.
\end{aligned}$$

Por tanto, las dos primeras observaciones quedan en la región de la clase -1, mientras que las dos últimas quedan en la región de la clase $+1$.

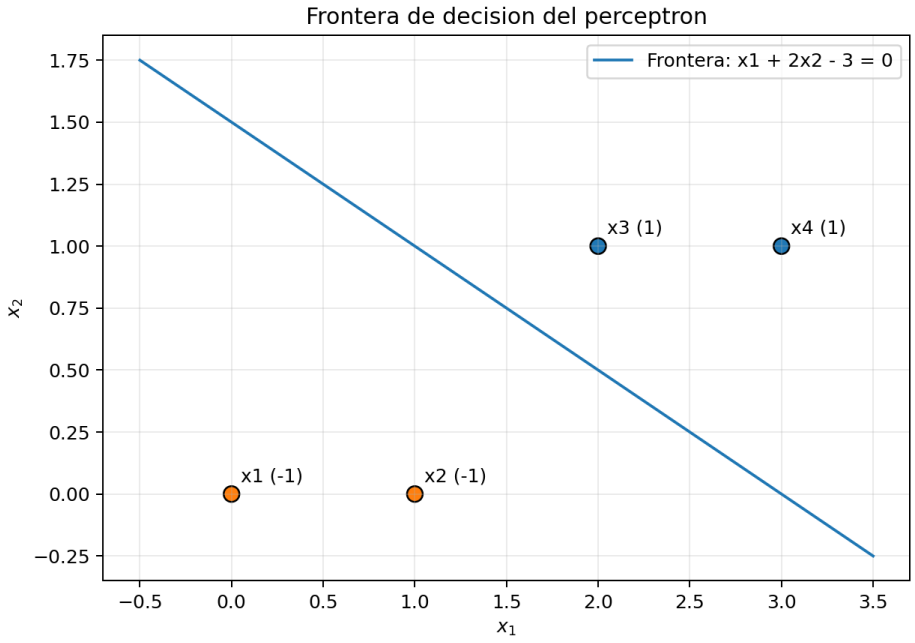


Figura 1: Frontera de decisión y clasificación de las cuatro observaciones.

1.2. 1.2. Actualización del perceptrón y cambio del margen

El margen de una observación $(\mathbf{x}_i, y_i)$ se define como

$$m_i = y_i(\mathbf{w}^\top \mathbf{x}_i + b).$$

La actualización del perceptrón es

$$\mathbf{w}_{\text{nuevo}} = \mathbf{w} + \eta y_i \mathbf{x}_i, \qquad b_{\text{nuevo}} = b + \eta y_i.$$

Para estudiar el margen después de la actualización, se sustituyen los nuevos parámetros en su definición:

$$\begin{aligned} m_{i,\text{nuevo}} &= y_i \left(\mathbf{w}_{\text{nuevo}}^\top \mathbf{x}_i + b_{\text{nuevo}} \right) \\ &= y_i \left[(\mathbf{w} + \eta y_i \mathbf{x}_i)^\top \mathbf{x}_i + (b + \eta y_i) \right] \\ &= y_i \left[\mathbf{w}^\top \mathbf{x}_i + \eta y_i \mathbf{x}_i^\top \mathbf{x}_i + b + \eta y_i \right] \\ &= y_i(\mathbf{w}^\top \mathbf{x}_i + b) + \eta y_i^2 \mathbf{x}_i^\top \mathbf{x}_i + \eta y_i^2. \end{aligned}$$

Como las etiquetas pertenecen a $\{-1, +1\}$, se cumple que $y_i^2 = 1$. Además, $\mathbf{x}_i^\top \mathbf{x}_i = \|\mathbf{x}_i\|_2^2$. Entonces,

$$\boxed{m_{i,\text{nuevo}} = m_i + \eta(\|\mathbf{x}_i\|_2^2 + 1)}.$$

El término que se suma es positivo porque $\eta > 0$ y $\|\mathbf{x}_i\|_2^2 + 1 > 0$. Por ello, la actualización aumenta el margen funcional de la observación que produjo el error. Sin embargo, un único paso no necesariamente hace positivo ese margen y tampoco garantiza que las demás observaciones queden bien clasificadas.

El margen funcional depende de la escala de $\mathbf{w}$ y b. Si $\mathbf{w} \neq \mathbf{0}$, el margen geométrico firmado es $\gamma_i = y_i(\mathbf{w}^\top \mathbf{x}_i + b)/\|\mathbf{w}\|_2$; por tanto, aumentar el margen funcional no implica necesariamente un aumento del margen geométrico normalizado. Además, el perceptrón converge en un número finito de actualizaciones cuando los datos de entrenamiento son linealmente separables; si no lo son, el algoritmo puede continuar actualizando sin converger.

1.3. 1.3. Ejercicio numérico

Se tienen $\mathbf{w} = [0, 0]^\top$, $b = 0$, $\eta = 0.5$, $\mathbf{x} = [2, 1]^\top$ y $y = +1$. Primero se evalúa la regla de predicción:

$$\mathbf{w}^\top \mathbf{x} + b = [0, 0] \begin{bmatrix} 2 \\ 1 \end{bmatrix} + 0 = 0.$$

Según el enunciado, cuando el resultado es menor o igual que cero se predice -1. Por tanto,

$$\hat{y} = -1 \neq y = +1,$$

así que la observación está mal clasificada y sí se debe actualizar.

Aplicando la regla:

$$\begin{aligned} \mathbf{w}_{\text{nuevo}} &= [0, 0]^\top + 0.5(1)[2, 1]^\top = [1, 0.5]^\top, \\ b_{\text{nuevo}} &= 0 + 0.5(1) = 0.5. \end{aligned}$$

El margen después de la actualización es

$$\begin{aligned} m_{\text{nuevo}} &= y(\mathbf{w}_{\text{nuevo}}^{\top}\mathbf{x} + b_{\text{nuevo}}) \\ &= 1\left([1, 0.5]\begin{bmatrix}2\\1\end{bmatrix} + 0.5\right) \\ &= 1(2 + 0.5 + 0.5) = \boxed{3}. \end{aligned}$$

El resultado también coincide con la expresión demostrada en el apartado anterior:

$$m_{\text{nuevo}} = 0 + 0.5(2^2 + 1^2 + 1) = 3.$$

2. Clasificación por los k vecinos más cercanos (k-NN)

2.1. 2.1. Cálculo manual de distancias

La observación que se desea clasificar es $q = (1, 1)$. Para cada punto del conjunto de entrenamiento se utiliza la distancia euclidiana:

$$d(q, \mathbf{x}_i) = \sqrt{(q_1 - x_{i,1})^2 + (q_2 - x_{i,2})^2}.$$

Las cinco distancias son:

$$\begin{aligned} d(q, \mathbf{x}_1) &= \sqrt{(1-0)^2 + (1-0)^2} = \sqrt{2} \approx 1.4142, \\ d(q, \mathbf{x}_2) &= \sqrt{(1-1)^2 + (1-0)^2} = 1, \\ d(q, \mathbf{x}_3) &= \sqrt{(1-3)^2 + (1-1)^2} = 2, \\ d(q, \mathbf{x}_4) &= \sqrt{(1-0)^2 + (1-3)^2} = \sqrt{5} \approx 2.2361, \\ d(q, \mathbf{x}_5) &= \sqrt{(1-1.1)^2 + (1-1.1)^2} = \sqrt{0.02} \approx 0.1414. \end{aligned}$$

El orden desde el vecino más cercano hasta el más lejano es:

Orden	Observación	Distancia	Clase
1	$\mathbf{x}_5 = (1.1, 1.1)$	0.1414	B
2	$\mathbf{x}_2 = (1, 0)$	1.0000	A
3	$\mathbf{x}_1 = (0, 0)$	1.4142	A
4	$\mathbf{x}_3 = (3, 1)$	2.0000	B
5	$\mathbf{x}_4 = (0, 3)$	2.2361	B

Cuadro 1: Distancias ordenadas respecto a $q = (1, 1)$.

A partir de este orden se realiza la votación mayoritaria:

- Para $k = 1$, el único vecino es $\mathbf{x}_5$, de clase B. La predicción es B.
- Para $k = 3$, los vecinos son B, A y A. La clase A obtiene dos votos, por lo que la predicción es A.

- Para $k = 5$, se consideran todos los puntos: hay dos votos para A y tres para B. La predicción es B.

El valor de k puede cambiar la predicción porque determina cuántas observaciones participan en la votación. Al aumentar k, se incorporan puntos más lejanos que pueden pertenecer a otra clase y modificar la mayoría. Como k-NN depende de distancias, las variables con escalas mayores pueden dominar el cálculo; cuando las unidades difieren, se deben estandarizar las características usando únicamente los datos de entrenamiento y aplicar esa misma transformación a validación y prueba. También conviene fijar una regla de desempate: un k impar reduce empates en problemas binarios, pero no los elimina en problemas con más clases.

2.2. 2.2. Implementación y evaluación con `make_moons`

Para estudiar el comportamiento de k-NN con datos bidimensionales, se genera un conjunto de 300 observaciones mediante `make_moons`, con ruido de 0.20 y semilla 42. Después se divide en 70 % para entrenamiento y 30 % para prueba. Se utiliza estratificación para conservar la proporción de las clases en ambos subconjuntos.

Se entrenan tres clasificadores, con $k = 1$, $k = 5$ y $k = 15$. La exactitud se calcula como la proporción de predicciones correctas sobre el total de observaciones evaluadas.

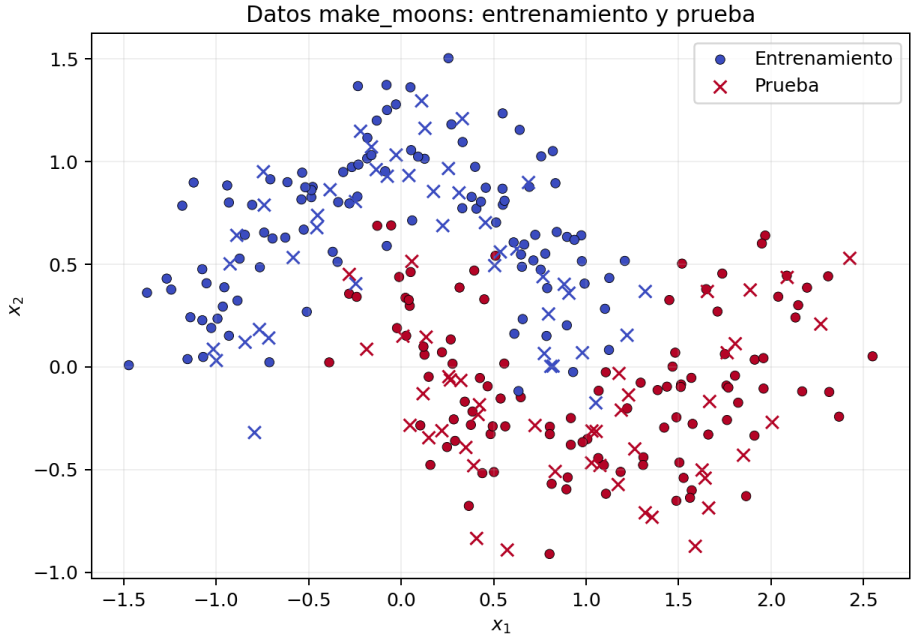


Figura 2: Distribución de los datos generados y separación entre entrenamiento y prueba.

Los resultados obtenidos al ejecutar el experimento son:

Vecinos k	Exactitud en entrenamiento	Exactitud en prueba
1	1.0000	0.9333
5	0.9571	0.9556
15	1.0000	0.9333

Cuadro 2: Exactitud de los clasificadores k-NN.

Las regiones de decisión permiten observar cómo cambia la clasificación del plano según el número de vecinos considerado.

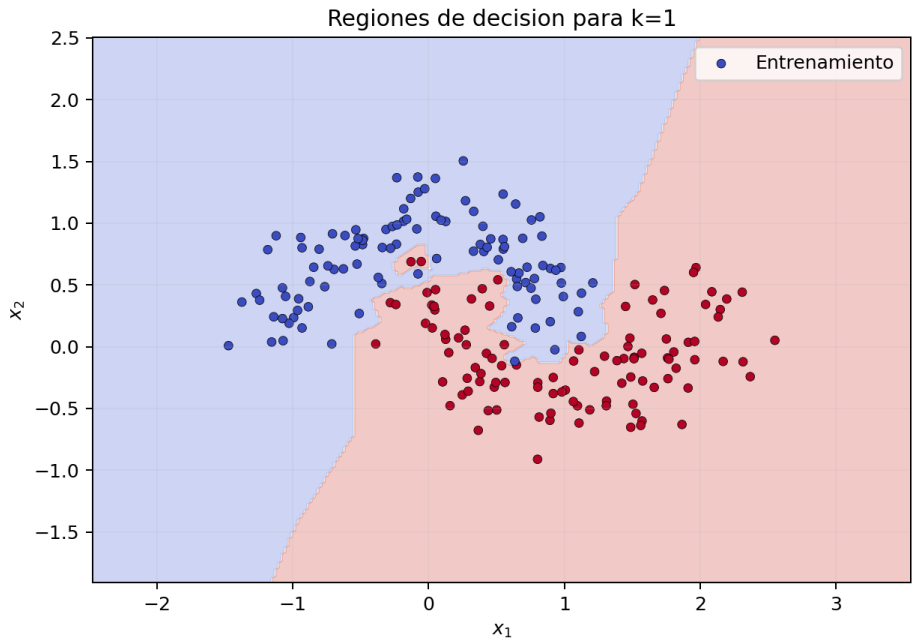


Figura 3: Regiones de decisión del clasificador k-NN con $k = 1$.

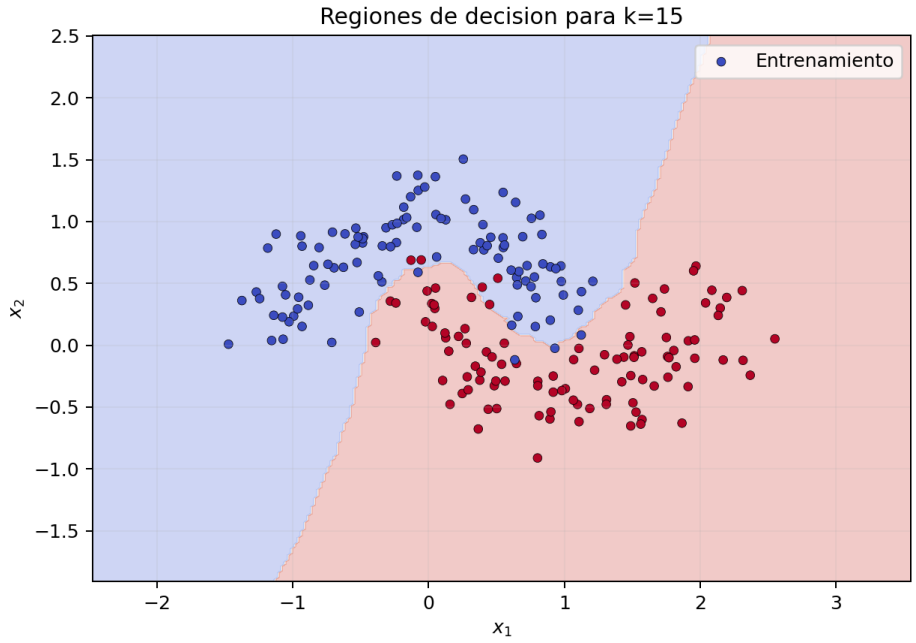


Figura 4: Regiones de decisión del clasificador k-NN con $k = 15$.

2.3. 2.3. Interpretación de los resultados

Cuando k es muy pequeño, la predicción depende de muy pocas observaciones. En el caso de $k = 1$, cada punto de prueba recibe la clase de su vecino más cercano. Esto puede

producir fronteras de decisión irregulares y una alta sensibilidad al ruido. En el extremo contrario, un valor grande de k considera más observaciones para votar, lo que genera fronteras más suaves, pero puede ignorar estructuras locales y favorecer excesivamente a la clase mayoritaria.

En esta partición, $k = 5$ alcanza la mayor exactitud de prueba (0.9556), frente a 0.9333 para $k = 1$ y $k = 15$. Como estos valores proceden de una sola división aleatoria, sus diferencias pueden variar con la partición. La selección de k debe hacerse mediante validación cruzada dentro del conjunto de entrenamiento; el conjunto de prueba se reserva para una evaluación final y se utiliza una sola vez.

3. Evaluación de un clasificador binario

3.1. 3.1. Matriz de confusión

Se consideran positivas las observaciones de clase 1. Al comparar las etiquetas verdaderas con las predicciones, se obtiene:

$$y = [0, 0, 0, 0, 1, 1, 1, 1, 1, 1], \qquad \hat{y} = [0, 1, 0, 0, 1, 0, 1, 1, 0, 1].$$

La matriz se organiza con las clases reales en las filas y las clases predichas en las columnas:

	Predicha 0	Predicha 1
Real 0	3	1
Real 1	2	4

De esta matriz se identifican:

$$TN = 3, \qquad FP = 1, \qquad FN = 2, \qquad TP = 4.$$

Hay tres negativos correctamente identificados, cuatro positivos correctamente identificados, un falso positivo y dos falsos negativos.

3.2. 3.2. Cálculo e interpretación de métricas

Exactitud (Accuracy). Mide la proporción total de predicciones correctas:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} = \frac{4 + 3}{4 + 3 + 1 + 2} = \boxed{0.70}.$$

El clasificador acertó el 70 % de las diez observaciones.

Precisión (Precision). Mide qué proporción de las predicciones positivas fue realmente positiva:

$$Precision = \frac{TP}{TP + FP} = \frac{4}{4 + 1} = \boxed{0.80}.$$

De todas las observaciones que el modelo predijo como positivas, el 80 % pertenecía efectivamente a la clase 1.

Sensibilidad (Recall). Mide qué proporción de los positivos reales fue identificada correctamente:

$$Recall = \frac{TP}{TP + FN} = \frac{4}{4+2} = \boxed{0.6667}.$$

El modelo identificó correctamente aproximadamente el 66.67 % de los positivos reales.

Medida F1. Combina precisión y sensibilidad mediante su media armónica:

$$F1 = 2\frac{Precision \cdot Recall}{Precision + Recall} = 2\frac{0.80(0.6667)}{0.80 + 0.6667} \approx \boxed{0.7273}.$$

Esta medida resume el equilibrio entre precisión y sensibilidad. Un valor alto requiere que ambas sean altas, pero F_1 no incorpora los verdaderos negativos. Por ello, puede complementarse con la especificidad y la exactitud balanceada:

$$\begin{aligned} \text{Especificidad} &= \frac{TN}{TN + FP} = \frac{3}{3+1} = 0.75, \\ \text{Exactitud balanceada} &= \frac{\text{Recall} + \text{Especificidad}}{2} \\ &= \frac{2/3 + 3/4}{2} = \frac{17}{24} \approx 0.7083. \end{aligned}$$

Estas medidas muestran explícitamente el desempeño al reconocer la clase negativa y equilibran el aporte de ambas clases.

3.3. 3.3. Verificación con scikit-learn y limitaciones de Accuracy

La matriz se presenta con las clases reales en las filas y las predichas en las columnas; la clase positiva es 1. La salida de la verificación se organiza a continuación:

Cuadro 3: Resultados de la verificación con `scikit-learn`.

Matriz de confusión

	Pred. 0	**Pred. 1**
Real 0	3	1
Real 1	2	4

Filas: clase real; columnas: clase predicha.

Métricas

Métrica	**Resultado**
Accuracy	`0.7`
Precision	`0.8`
Recall	`0.6666666666666666`
F1	`0.7272727272727273`

La exactitud por sí sola puede ser engañosa en, al menos, dos situaciones:

1. **Clases desbalanceadas:** si el 95 % de los ejemplos pertenece a la clase 0, un clasificador que siempre prediga 0 alcanzaría 95 % de exactitud, aunque no detectaría ningún positivo. En ese caso, la exactitud oculta el mal desempeño sobre la clase minoritaria.

2. **Errores con consecuencias diferentes:** en una aplicación médica, por ejemplo, no detectar a una persona enferma puede ser más grave que generar una falsa alarma. Dos modelos pueden tener la misma exactitud, pero diferentes cantidades de falsos negativos y falsos positivos. Por eso es necesario revisar también precisión, sensibilidad y la matriz de confusión.

Las métricas de precisión y sensibilidad también dependen del umbral usado para convertir puntajes en etiquetas. Reducir el umbral suele aumentar la sensibilidad, potencialmente a costa de más falsos positivos. El umbral debe elegirse según los costos del problema y ajustarse con validación, no con el conjunto de prueba; después se reportan las métricas en ese conjunto reservado.

4. Conclusiones

En este taller se estudiaron tres aspectos complementarios de la clasificación supervisada. Primero, se analizó un clasificador lineal y se verificó que la actualización del perceptrón aumenta el margen de la observación que ocasionó el error. Después, se aplicó k-NN, observando que la cantidad de vecinos influye directamente en la clase asignada y en la forma de las regiones de decisión. Finalmente, se evaluó un clasificador binario mediante la matriz de confusión y métricas que permiten distinguir distintos tipos de acierto y error.

En conjunto, los ejercicios muestran que no basta con obtener una predicción: también es necesario justificar cómo se obtiene, comprobar la implementación y elegir métricas acordes con el problema. Asimismo, la evaluación de un modelo debe separar los datos utilizados para entrenar y seleccionar el modelo de aquellos reservados para medir su desempeño final.